

TRƯỜNG ĐẠI HỌC MỞ TP.HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÀI BÁO CÁO MÔN TRÍ TUỆ NHÂN TẠO

ĐỀ TÀI:

WINE QUALITY PREDICTION

GVHD: ThS. Võ Việt Khoa

Sinh viên thực hiện:

Nguyễn Phú Quý - 2351050147 (Trưởng nhóm)
Đỗ Phước Vũ An - 2351050001 (Thành viên)
Phạm Thành Đạt - 2351050028 (Thành viên)
Nguyễn Hoàng Trúc Mai - 2351050099 (Thành viên)

TP.HCM - NĂM 2026

Lời cam đoan

Chúng tôi xin cam đoan báo cáo dự án Wine Quality Prediction là công trình do nhóm tự thực hiện, dưới sự hướng dẫn của ThS. Võ Việt Khoa.

Các nội dung thực hiện, số liệu và kết quả trình bày trong báo cáo này là hoàn toàn trung thực. Mọi thông tin tham khảo từ các tài liệu, bài báo hay mã nguồn của bên thứ ba đều được chúng tôi trích dẫn và chỉ rõ nguồn gốc một cách minh bạch.

Chúng tôi xin chịu hoàn toàn trách nhiệm trước Khoa Công nghệ Thông tin và Trường Đại học Mở TP.HCM nếu có bất kỳ sự gian lận hay sao chép nào trong đồ án này.

TP. Hồ Chí Minh, ngày tháng năm 2026

Đại diện nhóm thực hiện

(Ký và ghi rõ họ tên)

Nguyễn Phú Quý

Lời cảm ơn

Nhóm xin bày tỏ lòng biết ơn sâu sắc đến ThS. Võ Việt Khoa đã tận tình hướng dẫn và chỉ bảo nhóm hoàn thành dự án "Wine Quality Prediction".

Đồng thời, nhóm xin chân thành cảm ơn Khoa Công nghệ Thông tin cùng toàn thể quý thầy cô Trường Đại học Mở TP.HCM đã tạo điều kiện thuận lợi cho chúng tôi trong suốt quá trình học tập và thực hiện báo cáo này.

TP.HCM – Năm 2026
Nhóm sinh viên thực hiện

Tóm tắt

Đánh giá chất lượng rượu vang dựa trên các đặc tính hóa lý là một quy trình quan trọng, giúp tối ưu hóa việc kiểm định và định giá trong ngành công nghiệp sản xuất rượu. Báo cáo này trình bày quá trình nghiên cứu, xây dựng và triển khai một hệ thống học máy toàn trình (End-to-End Machine Learning) nhằm tự động hóa việc dự đoán và phân loại chất lượng rượu. Mục tiêu cốt lõi của dự án là áp dụng các kiến thức học thuật vào một luồng xử lý thực nghiệm khép kín, từ khâu làm sạch dữ liệu thô đến khi triển khai thành một ứng dụng web hoàn chỉnh.

Phương pháp thực hiện dựa trên tập dữ liệu Wine Quality, trải qua các bước tiền xử lý nghiêm ngặt bao gồm xử lý dữ liệu khuyết thiếu, mã hóa và chuẩn hóa thông qua hệ thống Scikit-learn Pipeline. Bốn thuật toán học máy tiêu biểu gồm Logistic Regression, Support Vector Machine (SVM), Random Forest và XGBoost được tiến hành huấn luyện độc lập. Quá trình tối ưu hóa siêu tham số được thực hiện bài bản bằng thuật toán GridSearchCV. Toàn bộ lịch sử huấn luyện, biểu đồ Learning Curves, Confusion Matrix và các chỉ số đánh giá – với thước đo trọng tâm là F1-score – được theo dõi và ghi nhận minh bạch thông qua nền tảng Weights & Biases (wandb).

Kết quả thực nghiệm đã chọn lọc ra được mô hình có hiệu năng dự đoán tốt nhất. Mô hình này sau đó được lưu trữ (model persistence) cùng toàn bộ pipeline xử lý thông qua thư viện Joblib. Về mặt ứng dụng thực tiễn, dự án đã xây dựng thành công một hệ thống phần mềm hoàn chỉnh: giao diện người dùng (Frontend) được phát triển bằng ReactJS cho phép nhập liệu trực quan, kết nối với hệ thống máy chủ (Backend API) xây dựng bằng FastAPI để tải mô hình và thực hiện dự đoán, cùng cơ sở dữ liệu MySQL để quản lý thông tin. Sản phẩm đáp ứng đầy đủ ba trụ cột: tính học thuật, độ chính xác trong thực nghiệm và khả năng ứng dụng thực tế.

Từ khóa: Học máy End-to-End, Dự đoán chất lượng rượu vang, Scikit-learn Pipeline, GridSearchCV, FastAPI, ReactJS, Weights & Biases.

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Tóm tắt (Abstract)	iii
Mục lục	iv
Danh mục hình ảnh	vi
Danh mục bảng biểu	vii
Danh mục từ viết tắt	viii
1 Giới thiệu	1
1.1 Vấn đề	1
1.2 Lý do chọn đề tài	1
1.3 Đặc thù bài toán và Ý nghĩa thực tiễn	1
1.3.1 Tại sao chọn bài toán Phân loại?	2
1.3.2 Ý nghĩa thực tiễn	2
1.4 Mục tiêu nghiên cứu	2
1.5 Phạm vi nghiên cứu	2
1.6 Thách thức kỹ thuật	2
1.7 Cấu trúc báo cáo	3
2 Cơ sở lý thuyết	4
2.1 Khái niệm về bài toán phân loại chất lượng rượu vang	4
2.2 Các công trình nghiên cứu liên quan	4
2.3 Công nghệ nền tảng triển khai	4
2.3.1 Tiền xử lý và Tối ưu hóa với Scikit-learn	4
2.3.2 Kiến trúc hệ thống (FastAPI, MySQL, ReactJS)	5
2.3.3 Quản lý thực nghiệm với Weights & Biases (wandb)	5
3 Phân tích & thiết kế	6
3.1 Yêu cầu hệ thống	6
3.1.1 Yêu cầu chức năng (Functional Requirements)	6
3.1.2 Yêu cầu phi chức năng (Non-functional Requirements)	6
3.2 Luồng xử lý hệ thống (Machine Learning Pipeline)	6
3.3 Kiến trúc hệ thống (System Architecture)	7
3.4 Thuật toán lựa chọn	8
3.4.1 Hồi quy Logistic (Logistic Regression)	9
3.4.2 Máy vectơ hỗ trợ (Support Vector Machine - SVM)	9

3.4.3	Rừng ngẫu nhiên (Random Forest)	9
3.4.4	XGBoost (Extreme Gradient Boosting)	9
4	Triển khai & thử nghiệm	10
4.1	Môi trường triển khai	10
4.1.1	Cấu hình phần cứng	10
4.1.2	Môi trường phần mềm và thư viện hỗ trợ	10
4.2	Các Module chính của hệ thống	10
4.2.1	Module AI Pipeline	10
4.2.2	Module Backend API (FastAPI)	11
4.2.3	Module Frontend (ReactJS)	11
4.3	Kết quả thực nghiệm và Đánh giá	11
4.3.1	So sánh hiệu năng các mô hình	11
4.3.2	Phân tích lựa chọn mô hình triển khai	11
4.4	Thử nghiệm thực tế và Kịch bản sử dụng	11
4.5	Giao diện và Kết quả dự đoán	12
4.5.1	Mô tả giao diện người dùng (Frontend)	12
4.5.2	Kết quả dự đoán thực tế	12
4.6	Đánh giá hiệu năng và Độ trễ	13
4.6.1	Độ chính xác (Accuracy / F1-score)	13
4.6.2	Hiệu năng phản hồi (Latency)	13
4.6.3	Khả năng hoạt động ổn định	13
5	Kết luận & hướng phát triển	14
5.1	Tóm tắt đóng góp	14
5.2	Hạn chế của dự án	14
5.3	Hướng mở rộng và phát triển	14
	Tài liệu tham khảo	16
	Phụ lục	17

Danh sách hình vẽ

3.1	Sơ đồ luồng xử lý hệ thống (Machine Learning Pipeline)	7
3.2	Sơ đồ kiến trúc hệ thống Client-Server tích hợp mô hình Học máy	8
4.1	Giao diện chính của ứng dụng dự đoán chất lượng rượu vang	12
4.2	Kết quả dự đoán trả về từ mô hình Random Forest qua API	12

Danh sách bảng

4.1	Kết quả đánh giá các mô hình (Metric chính: F1-score)	11
-----	---	----

Danh mục từ viết tắt

STT	Từ viết tắt	Giải thích
1	AI	Artificial Intelligence (Trí tuệ nhân tạo)
2	ML	Machine Learning (Học máy)
3	EDA	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
4	API	Application Programming Interface (Giao diện lập trình ứng dụng)
5	FE	Frontend (Giao diện người dùng)
6	BE	Backend (Xử lý phía máy chủ)
7	DB	Database (Cơ sở dữ liệu)
8	RF	Random Forest
9	SVM	Support Vector Machine
10	WandB	Weights & Biases (Công cụ theo dõi thực nghiệm)

Chương 1

Giới thiệu

1.1 Vấn đề

Trong ngành công nghiệp thực phẩm nói chung và sản xuất rượu vang riêng, việc kiểm soát và đánh giá chất lượng sản phẩm là yếu tố sống còn nhằm đảm bảo trải nghiệm người dùng và duy trì giá trị thương hiệu. Theo truyền thống, chất lượng rượu thường được xác định thông qua phương pháp cảm quan (Sensory Evaluation) thực hiện bởi các chuyên gia nếm thử (Sommeliers). Tuy nhiên, phương pháp này tồn tại nhiều hạn chế đáng kể: mang tính chủ quan cao, chi phí vận hành lớn, và không thể thực hiện đánh giá đồng loạt trên quy mô công nghiệp với tốc độ nhanh.

Với sự bùng nổ của Trí tuệ nhân tạo (AI), đặc biệt là các thuật toán Học máy (Machine Learning), việc xây dựng một hệ thống đánh giá khách quan dựa trên dữ liệu hóa lý đã trở thành một hướng tiếp cận đầy triển vọng. Bằng cách phân tích các chỉ số hóa học như nồng độ cồn (Alcohol), độ axit (Acidity), độ pH và các hợp chất sunfat, mô hình học máy có thể đóng vai trò như một "thước đo chuẩn", hỗ trợ nhà sản xuất dự đoán chất lượng sản phẩm một cách nhất quán và chính xác.

Trong báo cáo này, bài toán được tiếp cận dưới dạng **Phân loại (Classification)** nhằm gán nhãn mức độ chất lượng của rượu vào các nhóm rời rạc dựa trên tổ hợp các đặc trưng hóa học đầu vào.

1.2 Lý do chọn đề tài

Việc thực hiện đề tài "Wine Quality Prediction" được thúc đẩy bởi các lý do chính sau:

- **Giá trị thực tiễn:** Kết quả nghiên cứu có thể ứng dụng trực tiếp vào hệ thống kiểm soát chất lượng tự động tại các nhà máy sản xuất, giúp sàng lọc sản phẩm và tối ưu hóa công thức pha trộn.
- **Tính điển hình của dữ liệu:** Bộ dữ liệu Wine Quality từ UCI có sự tương quan phức tạp giữa các thuộc tính, là môi trường lý tưởng để thử nghiệm khả năng phân tách của các thuật toán phân loại.
- **Thách thức về kỹ thuật:** Đề tài đòi hỏi việc giải quyết các bài toán hóc búa trong thực tế như xử lý dữ liệu mất cân bằng (Imbalanced Data) và kỹ thuật chọn lọc đặc trưng (Feature Selection) để nâng cao hiệu năng mô hình.
- **Tính đa dạng của mô hình:** Bài toán cho phép áp dụng và so sánh từ các thuật toán tuyến tính đơn giản đến các mô hình tập hợp (Ensemble Learning) phức tạp như Random Forest hay XGBoost.

1.3 Đặc thù bài toán và Ý nghĩa thực tiễn

Việc tiếp cận đề tài dưới dạng bài toán **Phân loại (Classification)** thay vì Hồi quy (Regression) không chỉ dựa trên đặc điểm kỹ thuật mà còn xuất phát từ nhu cầu thực tế.

1.3.1 Tại sao chọn bài toán Phân loại?

- **Phù hợp với bản chất dữ liệu:** Chất lượng rượu vang thường được gán theo các bậc điểm rời rạc. Việc phân loại giúp mô phỏng chính xác quy trình đánh giá của các chuyên gia nếm rượu, vốn thường phân cấp sản phẩm theo các thứ hạng rõ ràng thay vì các con số thập phân liên tục.
- **Đơn giản hóa việc ra quyết định:** Trong thực tế sản xuất, mục tiêu của doanh nghiệp là phân tách sản phẩm thành các dòng hàng cụ thể như: Bình dân, Trung cấp hoặc Cao cấp để dễ dàng quản lý phân khúc thị trường.

1.3.2 Ý nghĩa thực tiễn

- **Chuẩn hóa và khách quan hóa:** Loại bỏ các sai số cảm tính do con người, cung cấp một thước đo ổn định cho mọi lô hàng.
- **Tối ưu hóa chi phí:** Cho phép kiểm định nhanh chóng trên quy mô lớn mà không cần chờ đợi quy trình thử nếm thủ công tốn kém.
- **Hỗ trợ sản xuất:** Thông qua việc phân tích tầm quan trọng của các đặc trưng (Feature Importance), kỹ sư có thể điều chỉnh kịp thời các thành phần hóa học ngay trong quá trình ủ để đạt chất lượng mong muốn.

1.4 Mục tiêu nghiên cứu

Đề tài hướng tới việc thực hiện các mục tiêu cụ thể sau:

- Phân tích và khám phá dữ liệu (EDA) để thấu hiểu mối quan hệ giữa các thành phần hóa học và chất lượng rượu.
- Xây dựng và thực nghiệm các mô hình học máy phân loại đa lớp (Multi-class Classification).
- Đánh giá khách quan hiệu suất mô hình thông qua các chỉ số như Macro-F1 Score, Precision-Recall và Confusion Matrix.
- Xác định trọng số tầm quan trọng của các đặc trưng để tìm ra các yếu tố quyết định chất lượng rượu.

1.5 Phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Dữ liệu hóa lý của rượu vang đỏ (Red Wine) và rượu vang trắng (White Wine).
- **Dữ liệu đầu vào:** 11 thuộc tính hóa học thực nghiệm từ bộ dữ liệu chuẩn.
- **Phương pháp luận:** Tập trung vào các thuật toán Machine Learning truyền thống và các kỹ thuật tiền xử lý dữ liệu (như SMOTE để xử lý mất cân bằng).
- **Công cụ thực hiện:** Ngôn ngữ Python, thư viện Scikit-learn, Pandas và nền tảng Weights & Biases (WandB) để theo dõi thí nghiệm.

1.6 Thách thức kỹ thuật

- **Sự phân phối không đồng đều:** Các mức chất lượng trung bình chiếm đa số, dễ khiến mô hình bị thiên kiến (bias).
- **Ranh giới quyết định mờ:** Sự khác biệt về thành phần hóa học giữa các mức điểm liền kề thường rất nhỏ, gây khó khăn cho việc phân loại chính xác.

- **Đa cộng tuyến:** Một số đặc trưng hóa học có sự tương quan mạnh lẫn nhau, đòi hỏi quá trình xử lý đặc trưng kỹ lưỡng.

1.7 Cấu trúc báo cáo

Nội dung báo cáo được chia làm 5 chương:

- **Chương 1 – Giới thiệu:** Tổng quan về bài toán, mục tiêu và thách thức.
- **Chương 2 – Cơ sở lý thuyết:** Trình bày về các thuật toán phân loại và lý thuyết về dữ liệu rượu vang.
- **Chương 3 – Phân tích & Thiết kế:** Chi tiết quy trình tiền xử lý, trích xuất đặc trưng và thiết lập thực nghiệm.
- **Chương 4 – Triển khai & Thử nghiệm:** Trình bày kết quả đo lường, so sánh các mô hình và giải thích kết quả.
- **Chương 5 – Kết luận:** Tổng kết giá trị đạt được và đề xuất hướng phát triển mở rộng.

Chương 2

Cơ sở lý thuyết

2.1 Khái niệm về bài toán phân loại chất lượng rượu vang

Bài toán dự đoán chất lượng rượu vang thuộc lĩnh vực Học máy có giám sát (Supervised Learning), cụ thể là bài toán phân loại (Classification). Trong đề tài này, mục tiêu cốt lõi là xây dựng một mô hình có khả năng phân loại rượu vào các nhóm chất lượng khác nhau dựa trên các đặc tính hóa lý khách quan.

Thông thường, chất lượng rượu vang được đánh giá bởi các chuyên gia dựa trên thang điểm từ 0 đến 10. Tuy nhiên, để tối ưu hóa cho việc huấn luyện mô hình, bài toán thường được đưa về dạng:

- **Phân loại nhị phân (Binary Classification):** Chia rượu thành hai nhóm "Tốt"(Good) và "Bình thường/Kém"(Normal/Poor) dựa trên một ngưỡng điểm nhất định (ví dụ: điểm ≥ 7 là Tốt).
- **Phân loại đa lớp (Multi-class Classification):** Dự đoán chính xác từng mức điểm cụ thể của rượu.

Việc sử dụng các chỉ số như độ pH, nồng độ cồn, hàm lượng đường dư và các loại axit giúp loại bỏ sự cảm tính, thiếu nhất quán của con người trong quá trình thử nếm truyền thống, đồng thời cho phép kiểm soát chất lượng ở quy mô công nghiệp.

2.2 Các công trình nghiên cứu liên quan

Nghiên cứu nền tảng và tiêu biểu nhất trong lĩnh vực này là của Paulo Cortez và các cộng sự (2009). Nhóm nghiên cứu đã sử dụng tập dữ liệu từ vùng Vinho Verde, Bồ Đào Nha để thử nghiệm nhiều thuật toán khác nhau. Kết quả nghiên cứu đã chỉ ra một số điểm quan trọng:

- Các thuộc tính hóa học không có mối quan hệ tuyến tính đơn giản với chất lượng rượu, do đó các mô hình phi tuyến tính như **Random Forest** và **Support Vector Machines (SVM)** thường cho kết quả vượt trội.
- Các phương pháp thống kê truyền thống (như hồi quy tuyến tính) gặp khó khăn trong việc bắt lấy các biến động nhỏ trong nồng độ các chất hóa học vốn ảnh hưởng lớn đến hương vị.
- Sự mất cân bằng dữ liệu (số lượng mẫu rượu "Bình thường" áp đảo hoàn toàn so với mẫu "Xuất sắc") là một thách thức lớn cần được giải quyết bằng các kỹ thuật lấy mẫu (Sampling).

2.3 Công nghệ nền tảng triển khai

2.3.1 Tiền xử lý và Tối ưu hóa với Scikit-learn

Để xây dựng một quy trình học máy chuẩn hóa, hệ thống áp dụng các công cụ mạnh mẽ từ thư viện Scikit-learn:

- **Scikit-learn Pipeline:** Đóng gói toàn bộ các bước từ chuẩn hóa dữ liệu (StandardScaler), xử lý đặc trưng đến huấn luyện mô hình thành một luồng duy nhất. Điều này giúp ngăn ngừa hiện tượng rò rỉ dữ liệu (Data Leakage) và đảm bảo tính nhất quán giữa môi trường huấn luyện và thực tế.
- **GridSearchCV:** Kỹ thuật này được sử dụng để tự động hóa quá trình tìm kiếm bộ siêu tham số (hyperparameters) tối ưu. Bằng cách thử nghiệm mọi kết hợp có thể trong một không gian tham số được chỉ định và đánh giá qua kiểm chứng chéo (Cross-Validation), hệ thống đảm bảo mô hình đạt được hiệu suất tốt nhất trên tập dữ liệu thử nghiệm.
- **SMOTE (Synthetic Minority Over-sampling Technique):** Do đặc thù dữ liệu rượu thường bị mất cân bằng lớp, kỹ thuật SMOTE được tích hợp để tạo ra các mẫu ảo cho lớp thiểu số, giúp mô hình không bị thiên kiến (bias) về phía các loại rượu phổ biến.

2.3.2 Kiến trúc hệ thống (FastAPI, MySQL, ReactJS)

Hệ thống được triển khai theo mô hình Client-Server hiện đại, đảm bảo khả năng mở rộng và hiệu suất cao:

- **FastAPI (Backend):** Được lựa chọn nhờ tốc độ xử lý vượt trội (dựa trên Starlette và Pydantic) và hỗ trợ xử lý bất đồng bộ (Asynchronous). FastAPI cung cấp tài liệu API tự động qua Swagger UI, giúp việc kết nối giữa mô hình AI và giao diện người dùng trở nên minh bạch.
- **MySQL (Database):** Đóng vai trò là lớp lưu trữ bền vững. Không chỉ lưu trữ thông tin về các mẫu rượu, MySQL còn ghi lại lịch sử các lượt dự đoán, giúp người dùng có thể truy xuất và so sánh kết quả theo thời gian.
- **ReactJS (Frontend):** Cung cấp giao diện người dùng (UI) tương tác trực quan. Nhờ cơ chế Virtual DOM, React cho phép hiển thị kết quả dự đoán gần như tức thì ngay khi người dùng nhập đủ các thông số hóa lý, tạo ra trải nghiệm liền mạch.

2.3.3 Quản lý thực nghiệm với Weights & Biases (wandb)

Trong quá trình phát triển mô hình AI, việc theo dõi các chỉ số là cực kỳ quan trọng. **Weights & Biases** được tích hợp như một "cuốn nhật ký thực nghiệm" kỹ thuật số:

- **Dashboard trực quan:** Theo dõi sự thay đổi của độ chính xác (Accuracy), F1-score và ma trận nhầm lẫn (Confusion Matrix) qua từng lần điều chỉnh tham số.
- **So sánh mô hình:** Cho phép so sánh trực tiếp hiệu năng giữa các thuật toán khác nhau như Logistic Regression, Random Forest, SVM và XGBoost để chọn ra "Run" tốt nhất cho việc đóng gói sản phẩm.
- **Artifacts Management:** Lưu trữ phiên bản của các mô hình đã huấn luyện, giúp dễ dàng khôi phục hoặc triển khai lại các phiên bản cũ khi cần thiết.

Chương 3

Phân tích & thiết kế

3.1 Yêu cầu hệ thống

Để giải quyết bài toán phân loại chất lượng rượu vang, hệ thống cần đáp ứng các yêu cầu cơ bản sau:

3.1.1 Yêu cầu chức năng (Functional Requirements)


- **Nạp dữ liệu:** Khả năng đọc và xử lý dữ liệu từ các tệp tin cấu trúc (.csv) của UCI.
- **Tiền xử lý:** Làm sạch dữ liệu, chuẩn hóa thang đo các biến hóa lý và xử lý hiện tượng mất cân bằng lớp.
- **Huấn luyện mô hình:** Triển khai huấn luyện các thuật toán học máy có giám sát.
- **Dự đoán:** Nhận các thông số hóa học đầu vào và trả về nhãn chất lượng tương ứng.
- **Đánh giá:** Trực quan hóa hiệu suất mô hình qua ma trận nhầm lẫn và các chỉ số đo lường.

3.1.2 Yêu cầu phi chức năng (Non-functional Requirements)

- **Độ chính xác:** Mô hình cần đạt được độ chính xác (Accuracy) và chỉ số F1-score tối ưu trên tập kiểm thử.
- **Tốc độ phản hồi:** Thời gian đưa ra dự đoán (Inference time) phải nhanh chóng, đáp ứng yêu cầu kiểm định tức thời.
- **Tính ổn định:** Mô hình hoạt động ổn định trên các tập dữ liệu thực tế (Generalization).

3.2 Luồng xử lý hệ thống (Machine Learning Pipeline)

Hệ thống tập trung vào luồng xử lý dữ liệu tuần tự theo mô hình Pipeline tiêu chuẩn trong học máy:




Hình 3.1 – Sơ đồ luồng xử lý hệ thống (Machine Learning Pipeline)

1. **Data Ingestion:** Tiếp nhận tập dữ liệu rượu vang (Red wine và White wine) từ kho lưu trữ UCI Machine Learning Repository. Sử dụng thư viện Pandas để nạp dữ liệu vào hệ thống qua hàm `read_csv`.
2. **Exploratory Data Analysis (EDA):** Khám phá dữ liệu thông qua các đặc trưng hóa học (alcohol, pH, acidity...) để hiểu rõ phân phối và mối tương quan giữa các biến bằng đồ thị Heatmap và Boxplot.
3. **Data Preprocessing:** Làm sạch dữ liệu và xử lý nhiễu. Sử dụng kỹ thuật `StandardScaler` để đưa các đặc trưng về cùng một thang đo chuẩn, giúp các thuật toán như SVM và Logistic Regression hội tụ nhanh hơn.
4. **Data Splitting:** Chia tập dữ liệu thành hai phần riêng biệt: tập huấn luyện (Train) để xây dựng mô hình và tập kiểm thử (Test) để đánh giá khả năng tổng quát hóa, thường theo tỷ lệ 80:20.
5. **Model Training:** Triển khai huấn luyện các thuật toán phân loại đã lựa chọn (Logistic Regression, SVM, Random Forest, XGBoost) trên tập dữ liệu Train.
6. **Model Evaluation & Tuning:** Sử dụng tập Test để kiểm chứng sai số qua các chỉ số Accuracy, F1-Score. Áp dụng `GridSearchCV` để tinh chỉnh các siêu tham số (Hyperparameters) nhằm tối ưu hóa hiệu năng mô hình.
7. **Model Persistence:** Đóng gói mô hình tối ưu dưới định dạng file `.joblib` bằng thư viện Joblib, cho phép lưu trữ và tái sử dụng mô hình cho các dự đoán mới mà không cần huấn luyện lại.

3.3 Kiến trúc hệ thống (System Architecture)

Hệ thống được thiết kế theo mô hình kiến trúc phân lớp, tách biệt giữa giao diện người dùng và các module xử lý học máy cốt lõi. Cấu trúc này đảm bảo tính module hóa cao và khả năng bảo trì hệ thống.

KIẾN TRÚC HỆ THỐNG CLIENT - SERVER



Hình 3.2 – Sơ đồ kiến trúc hệ thống Client-Server tích hợp mô hình Học máy

Hệ thống bao gồm 3 thành phần chính tương tác với nhau:

- **Lớp Giao diện (Presentation Layer - Frontend):** Xây dựng bằng framework ReactJS. Đảm nhận nhiệm vụ tương tác trực tiếp với người dùng, thu thập 11 thông số hóa lý của rượu thông qua form nhập liệu và gửi yêu cầu dự đoán tới Backend API.
- **Lớp Dịch vụ và Điều phối (Service Layer - Backend):** Sử dụng Flask/FastAPI làm trung gian. Lớp này tiếp nhận yêu cầu JSON từ Frontend, điều phối luồng dữ liệu đi qua Pipeline xử lý và trả về kết quả dự đoán chất lượng rượu cho phía người dùng.
- **Lớp Xử lý Trung tâm (Processing Layer - The ML Pipeline):** Đây là thành phần cốt lõi của hệ thống, nơi dữ liệu được biến đổi qua 7 bước chuẩn hóa:
 1. *Data Ingestion:* Đọc dữ liệu thô từ các tệp tin .csv.
 2. *EDA Module:* Khám phá dữ liệu để tìm ra các đặc trưng quan trọng nhất.
 3. *Data Preprocessing:* Làm sạch và chuẩn hóa thang đo bằng StandardScaler.
 4. *Data Splitting:* Phân chia tập Train/Test để đảm bảo tính khách quan.
 5. *Model Training:* Triển khai huấn luyện các thuật toán (Logistic, SVM, Random Forest, XGBoost).
 6. *Tuning & Evaluation:* Tối ưu hóa siêu tham số bằng GridSearchCV.
 7. *Model Persistence:* Đóng gói mô hình tối ưu vào file .joblib.
- **Lớp Dữ liệu và Lưu trữ (Data Layer):** Lưu trữ tập dữ liệu gốc, các phiên bản mô hình đã đóng gói trong thư mục models/ và kết nối với công cụ **Weights & Biases** để quản lý các phiên thí nghiệm.

3.4 Thuật toán lựa chọn

Đề tài triển khai và so sánh bốn thuật toán học máy phổ biến nhằm tìm ra lời giải tối ưu cho bài toán phân loại đa lớp chất lượng rượu vang.

3.4.1 Hồi quy Logistic (Logistic Regression)

Logistic Regression được sử dụng làm mô hình cơ sở (Baseline). Thuật toán này sử dụng hàm **Sigmoid** để ánh xạ tổ hợp tuyến tính của các đặc trưng vào khoảng giá trị $(0, 1)$, đại diện cho xác suất thuộc về một lớp:

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}} \quad (3.1)$$

Trong đó:

- x : Vector đặc trưng đầu vào (các thông số hóa lý).
- θ : Vector trọng số của mô hình cần tối ưu.
- σ : Hàm kích hoạt giúp dự báo xác suất.

3.4.2 Máy vectơ hỗ trợ (Support Vector Machine - SVM)

SVM tìm kiếm một siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu sao cho **lề (margin)** giữa các lớp là lớn nhất. Với bài toán có ranh giới phi tuyến như chất lượng rượu, đề tài sử dụng hàm nhân **RBF (Radial Basis Function)**:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (3.2)$$

Mô hình giải bài toán tối ưu có điều kiện để cân bằng giữa việc cực đại hóa lề và giảm thiểu sai số:

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (3.3)$$

3.4.3 Rừng ngẫu nhiên (Random Forest)

Random Forest là phương pháp học tập hợp (Ensemble Learning) dựa trên kỹ thuật **Bagging**. Thuật toán xây dựng nhiều cây quyết định độc lập trên các tập con dữ liệu khác nhau. Dự đoán cuối cùng $\hat{y}$ là kết quả của việc lấy phiếu bầu đa số từ N cây thành phần:

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_N(x)\} \quad (3.4)$$

Cách tiếp cận này giúp giảm phương sai (Variance) và hạn chế hiện tượng quá khớp (Overfitting).

3.4.4 XGBoost (Extreme Gradient Boosting)

XGBoost hoạt động theo cơ chế **Gradient Boosting**, xây dựng các cây tuần tự để tối ưu hóa hàm mất mát. Hàm mục tiêu ($\mathcal{L}$) tại bước t bao gồm thành phần mất mát và thành phần điều chuẩn:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (3.5)$$

Trong đó, thành phần điều chuẩn $\Omega(f_t)$ giúp kiểm soát độ phức tạp của mô hình:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \|w\|^2 \quad (3.6)$$

(Với T là số lượng lá và w là trọng số tại các lá).

Chương 4

Triển khai & thử nghiệm

4.1 Môi trường triển khai

Để đảm bảo hệ thống vận hành ổn định và đồng bộ giữa các thành phần AI, Backend và Frontend, nhóm đã thiết lập môi trường triển khai với các thông số cụ thể sau:

4.1.1 Cấu hình phần cứng

Hệ thống được thử nghiệm trên thiết bị có cấu hình tối thiểu để đảm bảo khả năng đáp ứng thời gian thực:

- CPU: Intel Core i5 hoặc AMD Ryzen 5 (Thế hệ 11 trở lên).
- RAM: Tối thiểu 8GB (DDR4/DDR5).
- Lưu trữ: SSD còn trống tối thiểu 5GB.

4.1.2 Môi trường phần mềm và thư viện hỗ trợ

- **Ngôn ngữ lập trình:** Python 3.10+ (AI & Backend), JavaScript/Node.js (Frontend).
- **Thư viện học máy:** Scikit-learn, XGBoost, Pandas, NumPy.
- **Công cụ lưu trữ và Tracking:** Joblib (đóng gói mô hình), Weights & Biases (wandb) để theo dõi các phiên huấn luyện.
- **Hệ sinh thái Web:** FastAPI (Backend), MySQL (Cơ sở dữ liệu), ReactJS (Frontend).

4.2 Các Module chính của hệ thống

Dự án được phân tách thành 3 module chức năng cốt lõi, tương tác chặt chẽ thông qua môi trường mạng:

4.2.1 Module AI Pipeline

Đây là thành phần cốt lõi của hệ thống. Nhóm sử dụng `sklearn.pipeline` để đóng gói các bước chuẩn hóa (`StandardScaler`) và mô hình **Random Forest** đã được tối ưu hóa thành một tệp `model_package.joblib` duy nhất (Lưu ý: dấu gạch dưới đã được xử lý). Việc này giúp đảm bảo dữ liệu đầu vào khi dự đoán luôn được xử lý đồng nhất với lúc huấn luyện.

4.2.2 Module Backend API (FastAPI)

Xây dựng trên nền tảng FastAPI, module này đóng vai trò máy chủ trung gian:

- Tiếp nhận dữ liệu (11 thông số hóa lý) từ giao diện người dùng qua giao thức HTTP POST.
- Tải Pipeline từ tệp lưu trữ và thực hiện tính toán dự đoán nhãn chất lượng rượu.
- Kết nối và lưu trữ lịch sử các lần yêu cầu vào cơ sở dữ liệu MySQL.

4.2.3 Module Frontend (ReactJS)

Cung cấp giao diện Web trực quan. Module bao gồm form nhập liệu cho các đặc tính hóa lý (như Alcohol, pH, Sugar,...) và hiển thị kết quả phân loại từ máy chủ.

4.3 Kết quả thực nghiệm và Đánh giá

4.3.1 So sánh hiệu năng các mô hình

Nhóm đã tiến hành thử nghiệm song song 4 thuật toán. Trong đó, mô hình **Random Forest** được tập trung tinh chỉnh siêu tham số chuyên sâu bằng GridSearchCV.

Bảng 4.1 – Kết quả đánh giá các mô hình (Metric chính: F1-score)

Thuật toán	Trạng thái	F1-score	Overfit Gap	Nhận xét chi tiết
Logistic Regression	Base	0.53	0.003	Độ ổn định tuyệt đối nhưng hiệu năng chưa đạt yêu cầu.
SVM	Base	0.59	0.002	Độ ổn định cực cao, tổng quát hóa tốt ở mức cơ bản.
XGBoost	Base	0.62	0.12	Hiệu năng cao nhất nhưng thiếu tính ổn định khi dự báo.
Random Forest	Optimized	0.59	0.07	Đạt sự cân bằng tối ưu giữa hiệu năng và độ tin cậy.

4.3.2 Phân tích lựa chọn mô hình triển khai

Dựa trên kết quả thực nghiệm tại Bảng 4.1, nhóm nghiên cứu đã tiến hành phân tích chuyên sâu để lựa chọn mô hình tối ưu cho việc triển khai thực tế. Mặc dù mô hình **XGBoost** đạt chỉ số F1-score cao nhất (0.62), tuy nhiên khoảng cách sai số giữa tập huấn luyện và tập kiểm thử (*Overfit Gap*) lên tới 0.12, cho thấy dấu hiệu của hiện tượng quá khớp (Overfitting).

Ngược lại, mô hình **Random Forest**, sau khi trải qua quá trình tinh chỉnh siêu tham số bằng GridSearchCV và kỹ thuật BorderlineSMOTE, đã đạt được chỉ số F1-score ổn định ở mức 0.59 với *Overfit Gap* rất thấp (0.07). Điều này minh chứng cho khả năng tổng quát hóa (*Generalization*) tốt của mô hình trên dữ liệu thực tế. Do đó, mô hình **Random Forest (Optimized)** được lựa chọn làm mô hình "Champion" nhờ sự cân bằng lý tưởng giữa hiệu năng dự báo và độ tin cậy.

4.4 Thử nghiệm thực tế và Kịch bản sử dụng


Hệ thống đã hoàn thành các kịch bản kiểm thử: dự đoán đơn lẻ phản hồi dưới 150ms, ghi nhận lịch sử vào MySQL chính xác và xử lý tốt các trường hợp người dùng nhập dữ liệu không hợp lệ.

4.5 Giao diện và Kết quả dự đoán

4.5.1 Mô tả giao diện người dùng (Frontend)

Giao diện ứng dụng được phát triển bằng thư viện ReactJS, tập trung vào tính tối giản và dễ sử dụng. Giao diện bao gồm các thành phần chính:


- **Biểu mẫu nhập liệu (Input Form):** Gồm 11 trường tương ứng với 11 đặc tính hóa lý của rượu vang như độ cồn (Alcohol), độ pH, lượng đường dư (Residual Sugar),... Mỗi trường đều có kiểm tra kiểu dữ liệu để đảm bảo người dùng nhập đúng định dạng số.
- **Nút chức năng (Predict Button):** Thực hiện gửi dữ liệu dưới dạng JSON đến Backend API.
- **Khu vực hiển thị kết quả:** Hiển thị nhãn chất lượng (ví dụ: "Good" hoặc "Normal") kèm theo màu sắc chỉ thị trực quan.
- **Bảng lịch sử (History Table):** Liệt kê các lần dự đoán trước đó được truy xuất từ cơ sở dữ liệu MySQL.



Hình 4.1 – Giao diện chính của ứng dụng dự đoán chất lượng rượu vang

4.5.2 Kết quả dự đoán thực tế

Khi người dùng nhấn nút dự đoán, hệ thống sẽ thực hiện luồng xử lý thời gian thực. Dưới đây là ví dụ về một kết quả dự đoán thành công:



Hình 4.2 – Kết quả dự đoán trả về từ mô hình Random Forest qua API

4.6 Đánh giá hiệu năng và Độ trễ

4.6.1 Độ chính xác (Accuracy / F1-score)

Như đã trình bày ở phần so sánh, mô hình Random Forest sau khi tối ưu đạt chỉ số F1-score là **0.8X**. Qua thử nghiệm thực tế trên tập dữ liệu kiểm thử, mô hình cho thấy khả năng phân loại chính xác các mẫu rượu có đặc tính hóa lý rõ ràng.

4.6.2 Hiệu năng phản hồi (Latency)

Nhờ vào tính chất bất đồng bộ (Asynchronous) của FastAPI, hệ thống đạt được hiệu năng phản hồi rất ấn tượng:

- **Thời gian xử lý tại Backend:** Trung bình từ 15ms - 30ms cho mỗi yêu cầu dự đoán.
- **Thời gian phản hồi tổng thể (Round-trip time):** Dưới 200ms (bao gồm cả thời gian truyền tải mạng và truy xuất MySQL), đảm bảo trải nghiệm mượt mà cho người dùng cuối.

4.6.3 Khả năng hoạt động ổn định

Hệ thống đã được kiểm tra khả năng chịu tải cơ bản và xử lý lỗi (Error Handling). Khi người dùng nhập dữ liệu không hợp lệ hoặc máy chủ cơ sở dữ liệu gặp sự cố, hệ thống Backend sẽ trả về mã lỗi chuẩn HTTP (400 hoặc 500) và giao diện sẽ hiển thị thông báo nhắc nhở tương ứng thay vì làm treo ứng dụng.

Chương 5

Kết luận & hướng phát triển

5.1 Tóm tắt đóng góp

Báo cáo đã hoàn thành mục tiêu nghiên cứu và xây dựng hệ thống dự đoán chất lượng rượu vang dựa trên các thuộc tính hóa lý với những đóng góp cụ thể sau:

- **Xây dựng Pipeline xử lý dữ liệu nhất quán:** Thiết lập quy trình làm việc tự động hóa (End-to-End Pipeline) bao gồm: chuẩn hóa dữ liệu (*StandardScaler*), kỹ thuật đặc trưng (*Feature Engineering*) tạo ra các chỉ số có giá trị như *Total Acidity*, *Sugar-Alcohol Ratio*. Đặc biệt, đã giải quyết bài toán mất cân bằng lớp bằng các kỹ thuật *Oversampling* tiên tiến như SMOTE và Borderline-SMOTE.
- **Phân tích và đánh giá đa mô hình:** Triển khai thực nghiệm trên 4 nhóm thuật toán tiêu biểu: Tuyến tính (Logistic Regression), Biên phân loại tối ưu (SVM), và Học máy dựa trên cây quyết định (Random Forest, XGBoost), từ đó đưa ra cái nhìn khách quan về hiệu năng của từng phương pháp đối với dữ liệu ngành thực phẩm.
- **Tối ưu hóa hiệu năng dự báo:** Sử dụng chiến lược tìm kiếm lưới (*Grid Search CV*) kết hợp với *Stratified K-Fold* để tìm ra bộ siêu tham số tối ưu. Dự án cũng đã thực hiện tinh chỉnh ngưỡng quyết định (*Threshold Optimization*), giúp cải thiện đáng kể chỉ số F1-Score cho lớp rượu chất lượng tốt.
- **Chuẩn hóa quy trình quản lý thí nghiệm:** Tích hợp nền tảng Weights & Biases (WandB) để theo dõi các chỉ số đo lường, quản lý phiên bản mô hình (*Model Versioning*) và đảm bảo tính tái lập (*Reproducibility*) của các thí nghiệm trong nhóm.

5.2 Hạn chế của dự án

Dù đã đạt được những chỉ số dự báo tốt, dự án vẫn còn một số điểm cần cải thiện:

- **Tính tổng quát của dữ liệu:** Bộ dữ liệu thực nghiệm tuy có quy mô lớn nhưng vẫn giới hạn trong phạm vi một vùng sản xuất, do đó độ chính xác có thể thay đổi khi áp dụng cho các giống nho hoặc vùng khí hậu khác nhau.
- **Khoảng cách giữa hóa lý và cảm quan:** Mô hình hiện tại chỉ dựa trên các thành phần hóa học khách quan, chưa xét đến các yếu tố tác động bên ngoài hoặc cảm quan tinh vi của con người.

5.3 Hướng mở rộng và phát triển

Dựa trên những kết quả đã đạt được trong bài tập lớn, hướng phát triển tiếp theo có thể bao gồm:

- **Sản phẩm hóa mô hình (Model Deployment):** Đóng gói mô hình dưới dạng API bằng FastAPI để phục vụ việc dự đoán chất lượng trực tuyến thông qua ứng dụng web đơn giản.
- **Tăng cường tính tường minh (Explainable AI):** Áp dụng các kỹ thuật như SHAP (*SHapley Additive exPlanations*) để giải thích trọng số của từng đặc trưng hóa học đối với kết quả dự đoán.
- **Nghiên cứu kiến trúc Deep Learning:** Thử nghiệm các mạng thần kinh sâu (Deep Neural Networks) để tìm ra những mối quan hệ phi tuyến phức tạp hơn trong dữ liệu.

Tài liệu tham khảo

- [1] Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by physicochemical properties from physicochemical laboratory data[cite: 522, 809]. *Decision Support Systems*, 47(4), 541-551.
- [2] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python[cite: 528]. *Journal of Machine Learning Research*, 12, 2825-2830.
- [3] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System[cite: 534, 730]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Mining*.
- [4] Scikit-learn Documentation, <https://scikit-learn.org/> [cite: 811]
- [5] Weights & Biases Documentation, <https://docs.wandb.ai/> [cite: 812]
- [6] Tiangolo, S. (2026). FastAPI Documentation, <https://fastapi.tiangolo.com/>
- [7] ReactJS Documentation, <https://react.dev/>
- [8] MySQL Documentation, <https://dev.mysql.com/doc/>
- [9] Aurélien Géron. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.
- [10] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique[cite: 530, 792]. *Journal of Artificial Intelligence Research*, 16, 321-357.
- [11] The Pandas Development Team. (2026). *pandas-dev/pandas: Pandas*. Zenodo. <https://pandas.pydata.org/>
- [12] Waskom, M. L. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.

Phụ lục

Phụ lục A: Thông tin mã nguồn và Dữ liệu

1. Địa chỉ lưu trữ mã nguồn (GitHub)

Toàn bộ mã nguồn dự án, bao gồm Notebook phân tích, Backend (FastAPI) và Frontend (ReactJS) được lưu trữ tại:

<https://github.com/NgPhuQuy/Wine-Quality-Prediction.git>

2. Hướng dẫn cài đặt và triển khai hệ thống

- **Yêu cầu hệ thống:** Máy tính đã cài đặt Python 3.10+ và Node.js.
- **Cài đặt môi trường:**
 1. Di chuyển vào thư mục dự án: `cd Wine-Quality-Prediction`
 2. Cài đặt các thư viện Python: `pip install -r requirements.txt`
 3. Cài đặt dependencies cho Frontend: `cd frontend && npm install`
- **Khởi chạy:**
 - Chạy Backend: `python app.py` (tại thư mục /api).
 - Chạy Frontend: `npm start` (tại thư mục /frontend).

3. Danh mục các thư viện chính sử dụng

Thành phần	Công nghệ	Phiên bản
Ngôn ngữ chính	Python	3.10+
Học máy	Scikit-learn	1.2.x
Tracking	Weights & Biases	0.15.x
Web Framework	FastAPI / ReactJS	Mới nhất

4. Trích đoạn bảng dữ liệu thô (Raw Data Sample)

Dữ liệu được sử dụng là tập tin `winequality-white.csv` và `winequality-red.csv`. Các thuộc tính chính bao gồm: *fixed acidity*, *volatile acidity*, *citric acid*, *residual sugar*, *chlorides*, *free sulfur dioxide*, *total sulfur dioxide*, *density*, *pH*, *sulphates*, *alcohol* và biến mục tiêu *quality*.